RAPORT

Testowanie modeli Whisper i Bielik na wypowiedziach matematycznych w języku polskim

Wydział: Inżynierii Mechanicznej i Robotyki

Kierunek: Inżynieria Akustyczna

Rok: 3

Przedmiot: Technologia mowy

Grupa: 3

Imię i nazwisko:

Mateusz Juszczak – *Team Leader*

Oliwia Chmura

Henryk Kosała

1. Cel projektu

Celem projektu jest zaprojektowanie i implementacja systemu do automatycznej analizy poprawności modeli rozpoznawania mowy (ASR) oraz przetwarzania języka naturalnego (NLP) na przykładzie wypowiedzi matematycznych w języku polskim. Projekt koncentruje się na ocenie jakości transkrypcji generowanych przez model Whisper oraz analizie wpływu błędów ASR na dalszą interpretację treści matematycznych przez model językowy Bielik.

System umożliwia ilościową ocenę skuteczności modeli poprzez porównanie transkrypcji z danymi referencyjnymi oraz analizę stabilności interpretacji równań matematycznych w obecności błędów rozpoznawania mowy.

2. Architektura systemu

2.1. Przygotowanie danych

Do realizacji projektu wykorzystano polskojęzyczny podzbiór korpusu Mozilla Common Voice. Zbiór ten zawiera nagrania mowy wraz z odpowiadającymi im transkrypcjami referencyjnymi (ground truth).

Ze względu na specyfikę projektu, dane zostały poddane dodatkowej selekcji w celu wyodrębnienia wypowiedzi zawierających elementy matematyczne, takie jak liczby oraz operatory arytmetyczne zapisane słownie. Proces filtrowania oparto na regułach językowych oraz heurystykach, co pozwoliło na uzyskanie powtarzalnego i niewielkiego zbioru testowego przeznaczonego do dalszych eksperymentów.

2.2. Model rozpoznawania mowy (Whisper)

Model Whisper (“base” 74M parametrów) pełni rolę systemu ASR, przekształcającego sygnał audio w reprezentację tekstową. W projekcie wykorzystano gotowe warianty modelu Whisper, które umożliwiają rozpoznawanie mowy w języku polskim bez dodatkowego treningu.

Wynikiem działania modelu jest transkrypcja nagrania audio, która następnie porównywana jest z transkrypcją referencyjną pochodzącą z korpusu Common Voice. Do ilościowej oceny jakości rozpoznawania mowy zastosowano miarę Word Error Rate (WER), umożliwiającą analizę częstości błędów w kontekście wypowiedzi matematycznych.

2.3. Analiza treści matematycznych – model Bielik

Transkrypcje wygenerowane przez model Whisper stanowią wejście dla modelu językowego Bielik (7B parametrów), który odpowiada za interpretację treści matematycznej wypowiedzi. Model Bielik wykorzystywany jest do:

- rozpoznawania struktury równania matematycznego,
- obliczania wyniku równania,
- klasyfikacji poprawności interpretacji.

Dla celów porównawczych model Bielik testowany jest również na transkrypcjach referencyjnych (ground truth), co pozwala ocenić bezpośredni wpływ błędów ASR na jakość przetwarzania NLP.

2.4. Ewaluacja

Ewaluacja systemu obejmuje dwa poziomy analizy:

1. Ocena ASR (Whisper):

- Word Error Rate (WER),
- analiza typowych błędów w rozpoznawaniu liczb i operatorów.

2. Ocena NLP (Bielik):

- skuteczność interpretacji równań matematycznych,
- porównanie wyników uzyskanych na ground truth oraz na transkrypcjach ASR,
- analiza propagacji błędów ASR do etapu NLP.

Dodatkowo możliwe jest przeprowadzenie analizy jakościowej poprzez ręczne przeglądy błędnych przypadków.

2.5. Optymalizacja architektury i metodyka PAL

W ramach prac implementacyjnych przetestowano zoptymalizowane podejście hybrydowe, dostosowane do specyfiki sprzętowej (GPU AMD). W badaniach wykorzystano model akustyczny Whisper w wariancie Base (ok. 74 mln parametrów) oraz model językowy Bielik-7B poddany 4-bitowej kwantyzacji w celu optymalizacji zużycia pamięci VRAM. Wdrożono podział obciążenia obliczeniowego, w którym transkrypcja ASR realizowana jest na

procesorze (CPU) przy użyciu biblioteki *faster-whisper* z kwantyzacją int8, natomiast model językowy uruchamiany jest na GPU w środowisku Ollama. Dodatkowo zmodyfikowano logikę działania modułu NLP, stosując podejście *Program-Aided Language Models* (PAL). W tym wariancie model Bielik nie wykonuje obliczeń bezpośrednio (co eliminuje ryzyko halucynacji numerycznych), lecz pełni funkcję parsera semantycznego, tłumaczącego język naturalny na wyrażenie w języku Python, którego wynik obliczany jest w sposób deterministyczny.

3. Plan kamieni milowych

Kamień milowy 1 – MVP

- Pobranie i przygotowanie danych z korpusu Common Voice.
- Implementacja automatycznego filtrowania wypowiedzi matematycznych.
- Uruchomienie modelu Whisper i generacja transkrypcji.
- Obliczenie WER dla wypowiedzi matematycznych.
- Wstępne testy modelu Bielik na transkrypcjach referencyjnych i ASR.

Kamień milowy 2 – Analiza wpływu błędów ASR

- Porównanie wyników Bielika dla ground truth i transkrypcji Whispera.
- Analiza przypadków, w których błędy ASR prowadzą do błędnej interpretacji równań.
- Kategoryzacja błędów (liczby, operatory, struktura równania).
- Wizualizacja wyników (rozkład WER, przykłady błędów).

Kamień milowy 3 – Optymalizacja i raport końcowy

- Testy różnych wariantów modelu Whisper.
- Analiza wpływu długości nagrania na jakość transkrypcji i interpretacji.
- Optymalizacja pipeline'u (batch processing, caching).
- Przygotowanie raportu końcowego wraz z wykresami, tabelami oraz wnioskami

4. Status pracy

4.1. Status na dzień 17.12.2025 r.

1. Przygotowanie bazy testowej nagrań.
2. Podział programu na moduły:

- dataset_download, gdzie:
    a) Konfiguracja środowiska i uwierzytelnienie połączenia API
    b) Pobieranie zbioru danych z dataset common voice
    c) Przygotowanie danych: rozpakowanie archiwum, walidacja danych i zapis do pliku
- program, gdzie:
    a) Implementacja wczytywania i obróbki danych podawanych na wejściu – usuwanie znaków, zamiana wielkości liter, lematyzacja tekstu: funkcja polish_text_to_math_expression(), flush_number()
    b) Konfiguracja i użycie modelu Whisper.
    c) Wstępna ewaluacja – Word Error Rate.
    d) Połączenie z modelem Bielik.

4.2. Zadania do wykonania

- Ewaluacja - NLP
- selekcja danych z Common Voice
- obliczenie surowej skuteczności
- analiza typowych błędów w rozpoznawaniu liczb i operatorów
- optymalizacja kodu